

OSNOVE UMETNE INTELIGENCE

2025/26

učenje odločitvenih dreves

učenje iz šumnih podatkov


ocenjevanje učenja

obravnavanje atributov

Pridobljeno znanje s prejšnjih predavanj

- različne **definicije** umetne inteligence
- filozofske in psihološke **implikacije** umetne inteligence
- **Turingov test**
- **zgodovina** umetne inteligence
- sodobne **aplikacije in področja** umetne inteligence
- **strojno učenje**
 - namen in cilji učenja
 - vrste učenja: nadzorovano, nenadzorovano, spodbujevano
 - nadzorovano učenje:
 - atributna predstavitev podatkov
 - klasifikacijski/regresijski problemi
 - prostor hipotez
 - evalvacija hipotez: konsistentnost, splošnost, preprostost/razumljivost/interpretabilnost

Pregled




- strojno učenje
 - uvod v strojno učenje
 - vrste strojnega učenja
 - predstavitev podatkov, hipoteze
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - ocenjevanje učenja
 - vrste atributov, diskretizacija, obravnava manjkajočih vrednosti


Odločitveno drevo

- ponazarja relacijo med vhodnimi vrednostmi (atributi) in odločitvijo (ciljna spremenljivka – razred ali označba)
 - notranja vozlišča: test glede na vrednost posameznega atributa
 - listi: odločitev (vrednost ciljne spremenljivke)
 - pot: konjunkcija pogojev v notranjih vozliščih na poti, ki vodi do lista
- poseben primer: binarna klasifikacija (razred ima dve možni vrednosti - npr. pozitivni/negativni, strupen/užiten itd.)

A	B	A xor B
F	F	F
F	T	T
T	F	T
T	T	F




Example	Attributes										Target WillWait
	Alt	Bar	Fri	Hun	Pat	Price	Rain	Res	Type	Est	
X ₁	T	F	F	T	Some	\$\$\$	F	T	French	0-10	T
X ₂	T	F	F	T	Full	\$	F	F	Thai	30-60	F
X ₃	F	T	F	F	Some	\$	F	F	Burger	0-10	T
X ₄	T	F	T	T	Full	\$	F	F	Thai	10-30	T
X ₅	T	F	T	F	Full	\$\$\$	F	T	French	>60	F
X ₆	F	T	F	T	Some	\$\$	T	T	Italian	0-10	T
X ₇	F	T	F	F	None	\$	T	F	Burger	0-10	F
X ₈	F	F	F	T	Some	\$\$	T	T	Thai	0-10	T
X ₉	F	T	T	F	Full	\$	T	F	Burger	>60	F
X ₁₀	T	T	T	T	Full	\$\$\$	F	T	Italian	10-30	F
X ₁₁	F	F	F	F	None	\$	F	F	Thai	0-10	F
X ₁₂	T	T	T	T	Full	\$	F	F	Burger	30-60	T



Gradnja odločitvenega drevesa

- cilj: zgradi **čim manjše** drevo, ki je **konsistentno** z učnimi podatki
- prostor iskanja: kombinatoričen, vsa možna drevesa (neučinkovito!)
- **hevristični požrešni algoritem** s strategijo **razveji in omeji**:
 - izberi najbolj pomemben atribut – tisti, ki najbolj odločilno vpliva na klasifikacijo primera – in razdeli primere v poddrevesa glede na njegove vrednosti,
 - rekurzivno ponovi za poddrevesa,
 - če vsi elementi v listu pripadajo istemu razredu ali vozlišča ni možno deliti naprej (ni razpoložljivih atributov), ustavi gradnjo.
- imenovano tudi **Top Down Induction of Decision Trees (TDIDT)**
- primeri implementacij: ID3, CART, Assistant, C4.5, C5, ...





Izbor najbolj pomembnega atributa

- najboljši atribut je tisti, ki razdeli učno množico v najbolj "čiste" podmnožice (glede na razred)
- uporabimo lahko **mero entropije**:

$$H = - \sum_k p_k \log_2 p_k$$

- mera nečistoče oz. mera nedoločenosti naključne spremenljivke (Shannon in Weaver, 1949)
- enota: količina informacije v bitih, ki jo pridobimo
- primeri:
 - met kovanca: 1 bit informacije
 - poskus s štirimi enako verjetnimi možnimi izidi: 2 bita informacije
 - poskus z dvema izidoma, od katerih je eden 99%: ~ 0 bitov informacije

Entropy




Informacijski prispevek

- dejansko nas zanima **znižanje entropije** (nedoločenosti) ob delitvi učne množice glede na vrednosti atributa A
- znižanje entropije ob delitvi učne množice glede na vrednosti atributa A
- **informacijski prispevek:**

$$Gain(A) = I - I_{res}(A)$$

$$I_{res} = - \sum_{v_i \in A} p_{v_i} \sum_c p(c|v_i) \log_2 p(c|v_i)$$

- najbolj informativni atribut **maksimizira informacijski prispevek** (minimizira I_{res})



informacija (entropija)
 $I = H(C)$


rezidualna informacija
(entropija)

$$I_{res} = \sum_i p_{v_i} \cdot H(C|v_i)$$


entropije, utežene z
verjetnostmi posameznih
poddreves

Izbor najbolj pomembnega atributa

Example	Attributes										Target
	Alt	Bar	Fri	Hun	Pat	Price	Rain	Res	Type	Est	WillWait
X ₁	T	F	F	T	Some	\$\$\$	F	T	French	0-10	T
X ₂	T	F	F	T	Full	\$	F	F	Thai	30-60	F
X ₃	F	T	F	F	Some	\$	F	F	Burger	0-10	T
X ₄	T	F	T	T	Full	\$	F	F	Thai	10-30	T
X ₅	T	F	T	F	Full	\$\$\$	F	T	French	>60	F
X ₆	F	T	F	T	Some	\$\$	T	T	Italian	0-10	T
X ₇	F	T	F	F	None	\$	T	F	Burger	0-10	F
X ₈	F	F	F	T	Some	\$\$	T	T	Thai	0-10	T
X ₉	F	T	T	F	Full	\$	T	F	Burger	>60	F
X ₁₀	T	T	T	T	Full	\$\$\$	F	T	Italian	10-30	F
X ₁₁	F	F	F	F	None	\$	F	F	Thai	0-10	F
X ₁₂	T	T	T	T	Full	\$	F	F	Burger	30-60	T



slab atribut (slabo loči pozitivne in negativne primere)



dober atribut (glej vrednosti None in Some)

- znižanje entropije ob delitvi učne množice glede na vrednosti atributa A

- $Gain(A) = I - I_{res}(A)$

$$I = -p(T) \log_2 p(T) - p(F) \log_2 p(F) = -\frac{6}{12} \log_2 \frac{6}{12} - \frac{6}{12} \log_2 \frac{6}{12} = -\log_2 \frac{1}{2} = 1$$

$$I_{res}(Type) = -\frac{2}{12} \left[\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2} \right] - \frac{2}{12} \left[\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2} \right] - \frac{4}{12} \left[\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4} \right] - \frac{4}{12} \left[\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4} \right] = 1$$



$$I_{res}(Patrons) = -\frac{2}{12} \cdot 0 - \frac{4}{12} \cdot 0 - \frac{6}{12} \left[\frac{2}{6} \log_2 \frac{2}{6} + \frac{4}{6} \log_2 \frac{4}{6} \right] \approx 0,46$$

$$Gain(Type) = 1 - 1 = 0$$

$$Gain(Patrons) = 1 - 0,46 = 0,54$$

Primer

- naučeno odločitveno drevo (levo) je krajše od ročno zgrajenega drevesa (desno)



- obe drevesi sta konsistentni s primeri
- v zgrajenem drevesu ne nastopajo vsi atributi (npr. *Raining* in *Reservation*), zakaj?

Večvrednostni atributi

- težava z atributi, ki imajo več kot dve vrednosti: informacijski prispevek precenjuje njihovo kakovost (entropija je višja na račun večjega števila vrednosti in ne na račun kakovosti atributa)
- primer: dve situaciji z enako nedoločenostjo razredov:
 - dve vrednosti: **111222**, $H = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{2}\log_2\frac{1}{2} = -\log_2\frac{1}{2} = 1$
 - tri vrednosti: **112233**, $H = -\frac{1}{3}\log_2\frac{1}{3} - \frac{1}{3}\log_2\frac{1}{3} - \frac{1}{3}\log_2\frac{1}{3} = -\log_2\frac{1}{3} = 1,58$
- rešitve:
 1. normalizacija informacijskega prispevka (**relativni informacijski prispevek**)
 2. uporaba **alternativnih mer** (informacijskih, ocene verjetnosti itd.)
 3. **binarizacija** atributov

Relativni informacijski prispevek in Gini

- Normalizacija informacijskega prispevka: **information gain ratio** (sistem ID3, Quinlan, 1986)

$$Gain(a) = I - I_{res}(A)$$

$$I(A) = - \sum_v p_v \log_2 p_v$$

$$GainRatio(A) = \frac{Gain(A)}{I(A)} = \frac{I - I_{res}(A)}{I(A)}$$

v – vrednost atributa

c – razred

informacija, ki jo potrebujemo
za določitev vrednosti atributa
A (entropija atributa)

- Alternativna mera za kakovost atributa: **Gini index**
 - ocena pričakovane klasifikacijske napake (vsota produktov verjetnosti razredov)

$$Gini = \sum_{c_1 \neq c_2} p(c_1)p(c_2)$$

$$Gini(A) = \sum_v p(v) \sum_{c_1 \neq c_2} p(c_1|v)p(c_2|v)$$

Izpitna naloga

- 2. izpitni rok, 15. 2. 2018 (prilagojena naloga)

Podana je učna množica primerov, ki je prikazana v tabeli (*vreme* in *pritisk* sta atributa, *glavobol* pa je razred). Naloge:

- a) Zgradi odločitveno drevo, pri čemer za ocenjevanje atributov uporabi informacijski prispevek. V primeru enakega števila primerov – predstavnikov obeh razredov – naj vozlišče klasificira v večinski razred iz učne množice.
- b) Ali bi dobljeno drevo bilo drugačno, če bi uporabili razmerje | informacijskega prispevka? Utemelji.
- c) V kateri razred bi drevo klasificiralo učni primer z vrednostmi atributov *vreme=deževno*, *pritisk=srednji*?

vreme	pritisk	glavobol
sončno	nizek	ne
sončno	nizek	ne
sončno	srednji	da
sončno	visok	ne
sončno	nizek	ne
sončno	nizek	da
deževno	srednji	ne
deževno	srednji	da
deževno	visok	da

Binarizacija atributov

- alternativa za reševanje problematike z večvrednostnimi atributi
- zalogo vrednosti atributa lahko razbijemo v dve množici
- primer: atribut $barva \in \{rdeča, rumena, zelena, modra\}$
- strategije:
 - $\{\{rdeča\}, \{rumena, zelena, modra\}\}$ (one-vs-all)
 - $\{\{rdeča, rumena\}, \{zelena, modra\}\}$
 - vpeljava binarnih atributov za vsako barvo
 - itd.
- prednost: manjše vejanje drevesa (statistično bolj zanesljivo, možna višja klasifikacijska točnost)
 - različne načine binarizacije atributa lahko nastopajo kot samostojni atributi, ki se v drevesu pojavijo večkrat

Kratkovidnost algoritma TDIDT

- TDIDT je požrešni algoritem, ki "lokalno" izbira najboljši atribut in ne upošteva, kako dobro drugi algoritmi dopolnjujejo izbrani atribut
- prednosti in slabosti zgornjega pristopa?
- kratkovidnost (angl. myopy) izbora atributa
- primer: problem XOR



A_1	A_2	Razred
0	0	0
0	1	1
1	0	1
1	1	0


$Gain(A_1) = ?$

$Gain(A_2) = ?$

$Gain(A_1 A_2) = ?$


Prostor hipotez odločitvenih dreves

- **diskretni atributi** - odločitvena drevesa delijo prvotno učno množico na vse manjše podmnožice (cilj: maksimizirati čistost podmnožic)
- **zvezni atributi** – delitev podmnožice glede na smiselno mejo izbranega atributa
- primera:



Tid	categorical		categorical		continuous		class
	Refund	Marital Status	Taxable Income	Cheat			
1	Yes	Single	125K	No			
2	No	Married	100K	No			
3	No	Single	70K	No			
4	Yes	Married	120K	No			
5	No	Divorced	95K	Yes			
6	No	Married	60K	No			
7	Yes	Divorced	220K	No			
8	No	Single	85K	Yes			
9	No	Married	75K	No			
10	No	Single	90K	Yes			



Training Data



Model: Decision Tree

Prostor hipotez odločitvenih dreves

- **zvezni atributi** (npr. višina, dolžina, IQ, koncentracija ozona, poraba el. energije, ipd.)
- v vozliščih običajno testiramo primerjavo zveznega atributa z izbrano mejo (večje/manjše)
- takšna odločitvena drevesa delijo prostor na particije (hiper-kvadre), katerih meje so vzporedne koordinatnim osem
- dva primera:



Privzeta točnost


- smiselna mera za **privzeto točnost** (minimalno pričakovano točnost) odločitvenega drevesa je **verjetnost večinskega razreda** v učni množici
- drevo je koristno/uporabno, če je njegova točnost **višja od privzete točnosti**

Primer:


- $[\text{\#Yes}, \text{\#No}] = [3, 7]$
- pričakovana točnost (verjetnost večinskega razreda) je 0,7
- želimo, da ima zgrajeno drevo na testnih podatkih višjo točnost

Pristranost na učni množici

- cilj: maksimiziraj pričakovano točnost drevesa (vendar ne na učnih podatkih - **pretirano prilagajanje?**)
- alternativa – uporaba **nevidenih primerov**:
 - izvzamemo posebno množico **testnih primerov**, če imamo dovolj podatkov (ostane manj podatkov za gradnjo)
 - tipična delitev podatkov: **učna množica** (70%), **testna množica** (30%)




Pregled



- strojno učenje
 - uvod v strojno učenje
 - vrste strojnega učenja
 - predstavitev podatkov, hipoteze
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - ocenjevanje učenja
 - vrste atributov, diskretizacija, obravnava manjkajočih vrednosti

Učenje dreves iz šumnih podatkov

- večja drevesa → večje prilagajanje učnih podatkom
- kaj pa, če podatki **niso popolni** (premalo primerov/atributov) ali so v učnih primerih **napake**? Pojavijo se lahko težave:
 - **učenje šuma** in ne dejanske (skrite) funkcije, ki generira podatke
 - pretirano prilagajanje vodi v **prevelika drevesa**
 - **slaba razumljivost** dreves
 - posledica: **nižja klasifikacijska točnost** na novih/nevidenih podatkih
- pojav **pretiranega prileganja** (angl. overfitting)
- rešitev: rezanje odločitvenega drevesa
- primer uspeha iz prakse → → → → →




primer iz prakse: lociranje primarnega tumorja (domena *Primary tumor*)

	Klas. točnost
Pretirano pril. drevo (150 vozlišč)	41%
Porezano drevo (15 vozlišč)	45%
Privzeta točnost	24,7%
Zdravniki	42%


Rezanje odločitvenih dreves – kako?

- **premislek:** nižji deli drevesa (bližji listom) predstavljajo večje lokalno prilagajanje učnim podatkom, ki so lahko posledica šuma
- **ideja:** odstranimo (režemo) spodnje dele drevesa, da dosežemo boljšo posplošitev naučenega drevesa (in klasifikacijsko točnost na nevidenih podatkih)
- primer nizke točnosti drevesa pri skrajnem primeru pretiranega prilagajanja:
 - dva razreda, c_1 in c_2 , $p(c_1) = 0,7$, $p(c_2) = 0,3$
 - privzeta točnost (točnost večinskega razreda) = 0,7
 - drevo, zgrajeno do konca (en primer v vsakem listu)
 - pričakovana točnost:
$$p_{c1} \times CA_{c1} + p_{c2} \times CA_{c2} =$$
$$= 0,7 \times 0,7 + 0,3 \times 0,3 = 0,58$$
(manj kot privzeta točnost!)






Rezanje odločitvenih dreves

- vprašanja:
 - kako to doseči,
 - kje rezati,
 - kombinatorično število možnih porezanih dreves




Strategije rezanja

- **rezanje vnaprej** (angl. *forward pruning, pre-stopping*): uporaba dodatnega kriterija za *zaustavitev gradnje drevesa* glede na obseg šuma (na podlagi: števila primerov, večinski razred, smiselnost delitve v poddrevesa glede na informacijski prispevek itd.)
 - **hitrejše**
 - **kratkovidno**, upošteva samo zgornji del drevesa
- **rezanje nazaj** (angl. *post-pruning*): rezanje, ki po gradnji celotnega drevesa, *odstrani manj zanesljive dele drevesa* (opisujejo šum, zgrajeni iz manj podatkov in z manj informativnimi atributi)
 - **počasneje**, oblika post-procesiranja
 - upošteva informacijo iz **celega drevesa**
 - pristopa:
 - **rezanje z zmanjševanjem napake (reduced error pruning, REP)**
 - **rezanje z minimizacijo napake (minimal error pruning, MEP)**



Rezanje z zmanjševanjem napake (REP)

- angl. *reduced error pruning* (REP)
- uporablja posebno rezalno (validacijsko) množico, potrebna primerna velikost za zanesljivost; tipične velikosti pri delitvi podatkov:
 - **učna množica** (70%), od tega:
 - množica za gradnjo (growing set) 70%
 - rezalna množica (pruning set) 30%
 - **testna množica** (30%)
- postopek:
 - potuj od listov navzgor (prični s starši listov)
 - za vsako vozlišče v izračunaj **dobitek rezanja**:
št. napačnih klasifikacij v drevesu T – št. napačnih klasifikacij v vozlišču v
 - če je dobiček ≥ 0 , obreži in nadaljuj postopek s staršem, sicer ustavi postopek




Rezanje z zmanjševanjem napake (REP)

- primer: podane so klasifikacije primerov iz rezalne množice v posameznih vozliščih, uporabi REP:

Legenda:

- [#Yes,#No]
- razred vozlišča
- (zeleno) pravilna klasifikacija
- (rdeče) napačna klasifikacija



Izpitna naloga

Legenda oznak v vozliščih:


- večinski razred: da
- vseh primerov v vozlišču: 8
- točnost v vozlišču (delež primerov, ki pripadajo večinskemu razredu v vozlišču) je $4/8=50\%$

- naloga, podobna izpitni nalogi (1. izpitni rok, 23. 1. 2019)

2. NALOGA (10t):

Podano je odločitveno drevo na sliki, ki ga uporabljamo za odločanje o nakupu valute Bitcoin. Drevo je zgrajeno iz učnih podatkov, ki imajo attribute: *zaupanje* (zaupanje v prodajalca – nizko ali visoko), *cena* (nakupna cena – ugodna ali draga) in *den_stanje* (lastno denarno stanje – slabo ali dobro). Razred je spremenljivka *nakup*, ki ima lahko vrednosti "da" (kupimo) ali "ne" (ne kupimo).

Legenda: Vozlišča v drevesu prikazujejo razred (da/ne), delež večinskega razreda in število primerov, ki pripadajo razredu da/ne.




- c) (3t) Z uporabo rezalne množice na desni strani poreži zgornje drevo s postopkom zmanjševanja napake (REP). Rezanje prikaži na zgornji skici drevesa.

zaupanje	cena	den_stanje	nakup
nizko	draga	dobro	ne
nizko	draga	dobro	ne
nizko	draga	slabo	da
nizko	ugodna	dobro	da
visoko	draga	dobro	ne
visoko	draga	slabo	da
visoko	draga	slabo	ne
visoko	draga	slabo	ne

Izpitna naloga

zaupanje	cena	den_stanje	nakup
nizko	draga	dobro	ne
nizko	draga	dobro	ne
nizko	draga	slabo	da
nizko	ugodna	dobro	da
visoko	draga	dobro	ne
visoko	draga	slabo	da
visoko	draga	slabo	ne
visoko	draga	slabo	ne



Rezanje z minimizacijo napake (MEP)

- angl. *minimal error pruning* (MEP) (Niblett in Bratko, 1986; Cestnik in Bratko, 1991)
- uporablja množico za gradnjo drevesa (in ne ločene rezalne množice)
- cilj: poreži drevo tako, da je ocenjena klasifikacijska napaka minimalna

- za vozlišče v izračunamo:

- **statično napako** (verjetnost klasifikacije v napačen razred)

$e(v) = p(\text{razred} \neq C|v)$, C je večinski razred v v

- **vzvratno napako** (angl. *backed-up error*)

$$\sum_i p_i E(T_i) = p_1 E(T_1) + p_2 E(T_2) + \dots$$


- režemo, če je **statična napaka manjša od vzvratne napake**

- **napaka optimalno obrezanega drevesa** je torej

$$E(T) = \min(e(v), \sum_i p_i E(T_i))$$


$$E(T) = e(v), \text{ če je } v \text{ list}$$

- (namesto **minimizacije napake** E (zgoraj) lahko problem obrnemo in **maksimiziramo točnost** CA – primer, ki sledi)



Ocenjevanje verjetnosti

- kako oceniti statično napako v vozlišču v ?
- primeri uporabe **relativne frekvence** (N – št. primerov v vozlišču, n – št. primerov, ki pripadajo večinskemu razredu C):
 - $N = 1, n = 1 \rightarrow$ točnost=100%
 - $N = 2, n = 1 \rightarrow$ točnost= 50% ? (samo z enim dodatnim primerom)
- težave:
 - potrebujemo *oceno verjetnosti*, ki je **stabilna** tudi pri manjšem številu primerov
 - **ocena verjetnosti**: mera, ki izraža **približek prave verjetnosti dogodka** in ima **zaželeno matematične lastnosti**, za njo pa ne veljajo nujno osnovni aksiomi s področja verjetnosti
 - smiselno je, da ocena verjetnosti upošteva tudi **apriorno verjetnost** (verjetnost, ki jo poznamo o problemu – npr. 50% za izid meta kovanca)



Ocenjevanje verjetnosti

boljši oceni verjetnosti:

- **Laplaceova ocena verjetnosti:**


$$p = \frac{n + 1}{N + k}$$

n – št. primerov, ki pripadajo razredu C,

N – št. vseh primerov

k – št. vseh razredov

- k je problematičen parameter; ocena ne upošteva apriorne verjetnosti



- **m-ocena verjetnosti**

$$p = \frac{n + p_a m}{N + m} = \overset{\text{delež upoštevanja apriorne verjetnosti}}{p_a} \cdot \overset{\text{delež upoštevanja relativne frekvence}}{\frac{m}{N + m}} + \frac{n}{N} \cdot \frac{N}{N + m}$$


p_a – apriorna verjetnost razreda C

m – parameter ocene (vpliva na delež upoštevanja apriorne verjetnosti)

- malo šuma – majhen m – malo rezanja / veliko šuma – velik m – veliko rezanja
- posplošitev Laplaceove ocene za $m = k$ in $p_a = 1/k$

Vaja

- primer: Bratko: Prolog Programming for AI
- Podano je odločitveno drevo za klasifikacijo v tri razrede (x, y in z) z naslednjimi apriornimi verjetnostmi razredov: $p_a(x) = 0,4$, $p_a(y) = 0,3$, $p_a(z) = 0,3$. Številke v oglatih oklepajih $[x, y, z]$ predstavljajo frekvence primerov v vozlišču, ki pripadajo ustreznim razredom. Obreži drevo s postopkom MEP in vrednostjo $m = 8$.



Vaja

$E(T) = \min(e(v), \sum_i p_i E(T_i))$, $E(T) = e(v)$, če je v list
 oziroma
 $CA(T) = \max(ca(v), \sum_i p_i CA(T_i))$, $CA(T) = ca(v)$, če je v list

- klasifikacijske točnosti v listih B1, B2 in B3:

$$p(x|B1) = \frac{n+m \cdot p_a(x)}{N+m} = \frac{5+8 \cdot 0,4}{5+8} = \mathbf{0,6308}$$

$$p(y|B1) = \frac{0+8 \cdot 0,3}{5+8} = 0,1846$$

$$p(z|B1) = \frac{0+8 \cdot 0,3}{5+8} = 0,1846$$

$$p(x|B2) = \frac{0+8 \cdot 0,4}{1+8} = 0,3556$$

$$p(y|B2) = \frac{1+8 \cdot 0,3}{1+8} = \mathbf{0,3778}$$

$$p(z|B2) = \frac{0+8 \cdot 0,3}{1+8} = 0,2667$$

$$p(x|B3) = \frac{1+8 \cdot 0,4}{3+8} = 0,3818$$

$$p(y|B3) = \frac{0+8 \cdot 0,3}{3+8} = 0,2182$$

$$p(z|B3) = \frac{2+8 \cdot 0,3}{3+8} = \mathbf{0,4}$$


- vzratna točnost v vozlišču B: $\frac{5}{9} \cdot 0,6308 + \frac{1}{9} \cdot 0,3778 + \frac{3}{9} \cdot 0,4 = 0,5257$

- statična točnost v vozlišču B:

$$p(x|B) = \frac{6+8 \cdot 0,4}{9+8} = \mathbf{0,5412}, p(y|B) = 0,2, p(z|B) = 0,2588$$

- statična točnost je večja od vzratne točnosti → porežemo

- nadaljujemo z vozliščema C in A ...



Vaja

$E(T) = \min(e(v), \sum_i p_i E(T_i))$, $E(T) = e(v)$, če je v list
 oziroma
 $CA(T) = \max(ca(v), \sum_i p_i CA(T_i))$, $CA(T) = ca(v)$, če je v list


- klasifikacijske točnosti v listih C1, C2 in C3:

$$\begin{aligned} p(x|C1) &= \frac{n+m \cdot p_a(x)}{N+m} = \frac{1+8 \cdot 0,4}{1+8} = \mathbf{0,4667} \\ p(y|C1) &= \frac{0+8 \cdot 0,3}{1+8} = 0,2667 \\ p(z|C1) &= \frac{0+8 \cdot 0,3}{1+8} = 0,2667 \end{aligned}$$

$$\begin{aligned} p(x|C2) &= \frac{0+8 \cdot 0,4}{5+8} = 0,2462 \\ p(y|C2) &= \frac{3+8 \cdot 0,3}{5+8} = \mathbf{0,4154} \\ p(z|C2) &= \frac{2+8 \cdot 0,3}{5+8} = 0,3385 \end{aligned}$$

$$\begin{aligned} p(x|C3) &= \frac{0+8 \cdot 0,4}{4+8} = 0,2667 \\ p(y|C3) &= \frac{0+8 \cdot 0,3}{4+8} = 0,2000 \\ p(z|C3) &= \frac{4+8 \cdot 0,3}{4+8} = \mathbf{0,5333} \end{aligned}$$

- vzvratna točnost v vozlišču C: $\frac{1}{10} \cdot 0,4667 + \frac{3}{10} \cdot 0,4154 + \frac{4}{10} \cdot 0,5333 = 0,4677$
- statična točnost v vozlišču C:
 $p(x|C) = 0,2333, p(y|C) = 0,3000, p(z|C) = \mathbf{0,4667}$
- vzvratna točnost je večja od
 statične točnosti $\rightarrow$ ne porežemo
- nadaljujemo z vozliščem A ...



Vaja

$E(T) = \min(e(v), \sum_i p_i E(T_i))$, $E(T) = e(v)$, če je v list
oziroma
 $CA(T) = \max(ca(v), \sum_i p_i CA(T_i))$, $CA(T) = ca(v)$, če je v list

- klasifikacijske točnosti CA v podrevesih s koreni v B in C:

$$CA(B) = \max(ca(B), \sum_i p_i CA(B_i)) = 0,5412$$


$$CA(C) = \max(ca(C), \sum_i p_i CA(C_i)) = 0,4677$$

- vzvratna točnost v vozlišču A: $\frac{9}{19} \cdot 0,5412 + \frac{10}{19} \cdot 0,4677 = 0,5025$


- statična točnost v vozlišču A:

$$p(x|A) = 0,3778, p(y|A) = 0,2370, p(z|A) = \frac{8+8 \cdot 0,3}{19+8} = \mathbf{0,3852}$$

- vzvratna točnost je večja od
statične točnosti $\rightarrow$ ne porežemo




Pregled




- strojno učenje
 - uvod v strojno učenje
 - vrste strojnega učenja
 - predstavitev podatkov, hipoteze
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - ocenjevanje učenja
 - vrste atributov, diskretizacija, obravnava manjkajočih vrednosti

Ocenjevanje učenja

- kriteriji za ocenjevanje hipotez:
 - **točnost** (angl. *accuracy*) (**konsistentnost**, **splošnost**)
 - **razumljivost** (angl. *comprehensibility*) – subjektivni kriterij ali tudi **kompleksnost** (angl. *complexity*)
- ocenjevanje točnosti:
 - na **učnih** podatkih (angl. *training set, learning set*)
 - na **testnih** podatkih (angl. *testing set, test set*)
 - izločimo del učnih podatkov, s katerimi simuliramo ne-videne podatke
 - želimo si, da je testna množica reprezentativna za nove podatke
 - uporabimo lahko **intervale zaupanja** v oceno uspešnosti na testni množici, ki upoštevajo število testnih primerov
 - na **novih** (ne-videnih) podatkih (angl. *new data, unseen data*)
 - na njih bo naučeni sistem dejansko deloval




Ocenjevanje učenja



- nasprotujoča si cilja:
 - potrebujemo čim več podatkov za **uspešno učenje**
 - potrebujemo čim več podatkov za **zanesljivo ocenjevanje točnosti** (večje število testnih primerov nam daje ožji interval zaupanja v oceno točnosti)
- rešitev:
 - kadar je učnih podatkov dovolj, lahko izločimo **testno množico** (angl. *holdout test set*)
 - alternativa: **večkratne delitve** na učno in testno množico
- različni načini **vzorčenja testnih primerov**:
 - naključno, nenaključno (npr. prečno preverjanje)
 - poljubno ali stratificirano (zagotovimo enako porazdelitev razredov kot v učni množici)


Prečno preverjanje

- poseben primer **večkratnega učenja** in testiranja
- **k-kratno prečno preverjanje** (angl. *k-fold cross-validation*):
 - celo učno množico razbij na k disjunktih podmnožic
 - za vsako od k podmnožic:
 - uporabi **množico** kot **testno množico**
 - uporabi **preostalih $k-1$** množic kot **učno množico**
 - povpreči dobljenih k ocen točnosti v končno oceno




Prečno preverjanje

- v praksi **najpogosteje: $k=10$** (10-kratno prečno preverjanje)
- vplive izbranega razbitja podatkov na podmnožice lahko zmanjšamo tako, da tudi prečno preverjanje **večkrat (npr. 10x) ponovimo** (torej $10 \times 10 = 100$ izvajanj učnega algoritma) in rezultate povprečimo
- poseben primer prečnega preverjanja je metoda **izloči enega** (angl. leave-one-out, LOO)
 - k je enak številu primerov (vsaka testna množica ima samo en primer)
 - najbolj stabilna ocena glede učinkov razbitja na podmnožice
 - časovno zelo zamudno, primerno za manjše množice
- iz meritev na vseh podmnožicah je možno izračunati tudi varianco/ intervale zaupanja



Pregled



- strojno učenje
 - uvod v strojno učenje
 - vrste strojnega učenja
 - predstavitev podatkov, hipoteze
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - ocenjevanje učenja
 - vrste atributov, diskretizacija, obravnava manjkajočih vrednosti

Različne vrste atributov

- vrste atributov:
 - diskretni:
 - nominalni ({true, false}, {M, F}, {French, Thai, Burger, Italian})
 - ordinalni ({None, Some, Full}, {Low, Med, High})
 - zvezni/numerični ($\in \mathbb{R}$)
- Kako obravnavati zvezne/numerične attribute?
 - Običajno izvedemo diskretizacijo v dva (binarizacija) ali več diskretnih intervalov.
 - Različni pristopi k diskretizaciji:
 - intervali **enake širine** (equal-width)
 - intervali z **enako frekvenco** primerov (equal-frequency)
 - intervali, ki **maksimizirajo informacijski prispevek**

• **Data** : 0, 4, 12, 16, 16, 18, 24, 26, 28


• **Equal width**

- Bin 1: 0, 4 $[-, 10)$
- Bin 2: 12, 16, 16, 18 $[10, 20)$
- Bin 3: 24, 26, 28 $[20, +)$


• **Equal frequency**

- Bin 1: 0, 4, 12 $[-, 14)$
- Bin 2: 16, 16, 18 $[14, 21)$
- Bin 3: 24, 26, 28 $[21, +)$

Equal width




Equal frequency




Diskretizacija z maksimizacijo informacijskega prispevka

- numerični atributi namesto diskretnih?

Day	Outlook	Temperature	Humidity	Wind	Play
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool			
7	Overcast	Cool			
8	Sunny	Mild			
9	Sunny	Cool			
10	Rain	Mild			
11	Sunny	Mild			
12	Overcast	Mild			
13	Overcast	Hot			
14	Rain	Mild			




Day	Outlook	Temperature	Humidity	Windy	Play
1	Sunny	85	85	Weak	No
2	Sunny	80	90	Strong	No
3	Overcast	83	86	Weak	Yes
4	Rain	70	96	Weak	Yes
5	Rain	68	80	Weak	Yes
6	Rain	65	70	Strong	No
7	Overcast	64	65	Strong	Yes
8	Sunny	72	95	Weak	No
9	Sunny	69	70	Weak	Yes
10	Rain	75	80	Weak	Yes
11	Sunny	75	70	Strong	Yes
12	Overcast	72	90	Strong	Yes
13	Overcast	81	75	Weak	Yes
14	Rain	71	91	Strong	No



Diskretizacija z maksimizacijo informacijskega prispevka

- kako diskretizirati atribut Humidity?



Day	Outlook	Temperature	Humidity	Windy	Play
1	Sunny	85	85	Weak	No
2	Sunny	80	90	Strong	No
8	Sunny	72	95	Weak	No
9	Sunny	69	70	Weak	Yes
11	Sunny	75	70	Strong	Yes

- primeri možni vrednosti za mejo x: 70, 85, 90

- entropije ob različnih delitvah:

- $x = 70 \rightarrow$ levo $[2,0]$, desno $[0,3]$
 $H_{res} = \frac{2}{5} \cdot 0 + \frac{3}{5} \cdot 0 = 0$ ← najnižja residualna entropija (najvišji informacijski prispevek)
- $x = 85 \rightarrow$ levo $[2,1]$, desno $[0,2]$
 $H_{res} = \frac{3}{5} \cdot \left(-\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} \right) + \frac{2}{5} \cdot 0 = 0,551$
- $x = 90 \rightarrow$ levo $[2,2]$, desno $[0,1]$
 $H_{res} = \frac{4}{5} \cdot 1 + \frac{1}{5} \cdot 0 = 0,8$

- izberemo:

- LOW: ≤ 70
- HIGH: > 70


Obravnava manjkajočih atributov

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
8	Sunny	Mild	???	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes

- različni načini **obrnave manjkajočih** atributov, glede na:
 - ali učni algoritem lahko poišče hipotezo **tudi, če manjkajo** vrednosti atributov?
 - ali imamo **dovolj** učnih primerov na razpolago?
 - ali je primerno **nadomeščanje** manjkajočih vrednosti?
- **pristopi pri učenju:**
 - učimo z manjkajočimi vrednostmi
 - ignoriranje celih učnih primerov z neznanimi vrednostmi
 - uporaba posebne vrednosti NA/UNKNOWN?
 - nadomestiti manjkajočo vrednost (povprečna, najbolj pogosta, najbolj pogosta glede na razred, naključna, napovedana)
 - primer obravnavamo verjetnostno glede na vse možne vrednosti atributa
- **pristopi pri napovedovanju:**
 - verjetnostna klasifikacija glede na vse možne vrednosti atributa (npr. pri drevesu: klasificiramo v več listov)

Obravnava manjkajočih atributov

- Kako klasificirati primer
Outlook=Sunny,
Temperature=Mild,
Humidity=???,
Wind=Weak ?
- verjetnostna klasifikacija glede na relativno frekvenco:
 - $P(\text{razred} = \text{No} \mid \text{primer}) = 3/5$
 - $P(\text{razred} = \text{Yes} \mid \text{primer}) = 2/5$





Naivni Bayes, kNN, regresija