


OSNOVE UMETNE INTELIGENCE

2025/26

*naivni Bayesov klasifikator
nomogrami
k najbližjih sosedov*

Pregled

- strojno učenje
 - uvod v strojno učenje
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - ocenjevanje učenja
 - diskretizacija atributov, obravnava manjkajočih vrednosti
 - naivni Bayesov klasifikator
 - nomogrami
 - k najbližjih sosedov
 - lokalno utežena regresija
 - regresijska drevesa
 - linearna regresija
 - nevronske mreže
 - nenadzorovano učenje



Naivni Bayesov klasifikator

- Thomas Bayes, 1702 – 1761
- opomnik iz teorije o verjetnosti:


$$P(AB) = P(A|B) \cdot P(B)$$

$$P(AB) = P(B|A) \cdot P(A)$$

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

Bayesovo pravilo




Naivni Bayesov klasifikator

- zdravniki razpolagajo z **vzročno in statistično informacijo** o simptomih (opažanja) in diagnozah (hipoteza):
 - verjetnost **izraženih simptomov pri neki bolezni** - $P(\text{opažanje}|\text{hipoteza})$
 - verjetnost **določene bolezni** - $P(\text{hipoteza})$
 - verjetnost **določenega simptoma** - $P(\text{opažanje})$

- aplikacija v medicini:


$$P(\text{hipoteza}|\text{opažanje}) = \frac{P(\text{opažanje}|\text{hipoteza}) \cdot P(\text{hipoteza})}{P(\text{opažanje})}$$

- Bayesovo pravilo nam izraža **diagnostično pogojno verjetnost** $P(\text{hipoteza}|\text{opažanje})$ na podlagi **vzročne pogojne verjetnosti** $P(\text{opažanje}|\text{hipoteza})$



Vaja – opomnik iz verjetnosti

- dve vrsti vrečk s frnikulami:
 - 4 vrečke tipa A (vsaka 5 črnih, 15 belih frnikul)
 - 1 vrečka tipa B (16 črnih, 4 bele frnikule)
- primeri vprašanj, zapisanih kot verjetnosti:
 - Kakšna je verjetnost, da je to vrečka tipa B?
 $P(B) = ?$
 - Kakšna je verjetnost, da naključno izberemo črno frnikulo, če izbiramo iz vrečke tipa B?
 $P(\check{C}|B) = ?$
 - Naključno izberemo eno izmed vrečk in iz nje naključno izberemo frnikulo. Kakšna je verjetnost, da smo izbrali črno frnikulo iz vrečke tipa B?
 $P(B\check{C}) = P(B) \cdot P(\check{C}|B) = ?$
 - Naključno izberemo eno izmed vrečk in iz nje naključno izberemo frnikulo. Kakšna je verjetnost, da smo izbrali črno frnikulo?
 $P(\check{C}) = P(B) \cdot P(\check{C}|B) + P(A) \cdot P(\check{C}|A)$



Vaja

- Ena vrečka ima poškodovan ovoj tako, da se skozi njega vidi črna frnikula. Kakšna je verjetnost, da je to vrečka tipa B?

$$P(B|\check{C}) = ?$$

- B = hipoteza, Č = evidenca, opažanje
- verjetnost $P(B|\check{C})$ lahko določimo iz drugih bolj očitnih verjetnosti z Bayesovo formulo:

$$P(B|\check{C}) = \frac{P(B) \cdot P(\check{C}|B)}{P(\check{C})}$$

- $P(B) = \frac{1}{5} = 0,2$
 $P(\check{C}|B) = \frac{16}{20} = 0,8$
 $P(\check{C}) = \frac{4 \cdot 5 + 1 \cdot 16}{5 \cdot 20} = 0,360$
- $P(B|\check{C}) = \frac{0,2 \cdot 0,8}{0,360} = 0,444$

dve vrsti vrečk s frnikulami:

- 4 vrečke tipa A (vsaka 5 črnih, 15 belih frnikul)
- 1 vrečka tipa B (16 črnih, 4 bele frnikule)

Naivni Bayes v strojnem učenju

- evidenca → atributi
hipoteza → razred
- zanima nas, kakšna je verjetnost razreda C pri podanih vrednostih atributov

$$A_1 = X_1, A_2 = X_2, \dots, A_n = X_n:$$

$$P(C|X_1X_2 \dots X_n) = \frac{P(C) \cdot P(X_1X_2 \dots X_n|C)}{P(X_1X_2 \dots X_n)}$$

The diagram shows the equation $P(c|x) = \frac{P(x|c)P(c)}{P(x)}$ with three labels and arrows pointing to the corresponding terms:

- Likelihood** points to $P(x|c)$.
- apriorna verjetnost razreda** (Class Prior Probability) points to $P(c)$.
- aposteriorna verjetnost napovedi** points to $P(c|x)$.

The equation is presented as:

$$P(c|x) = \frac{P(x|c)P(c)}{P(x)}$$

Naivni Bayes v strojnem učenju

$$P(\text{hipoteza}|\text{evidenca}) = \frac{P(\text{hipoteza}) \cdot P(\text{evidenca}|\text{hipoteza})}{P(\text{evidenca})} \longrightarrow P(C|X_1X_2 \dots X_n) = \frac{P(C) \cdot P(X_1X_2 \dots X_n|C)}{P(X_1X_2 \dots X_n)}$$

- pravilo za produkt verjetnosti: $P(AB) = P(A) \cdot P(B|A)$
- pravilo za produkt verjetnosti s pogojno verjetnostjo: $P(AB|C) = P(A|C) \cdot P(B|AC)$

- $$\begin{aligned} P(X_1X_2 \dots X_n|C) &= P(X_1|C) \cdot P(X_2 \dots X_n|X_1C) = \\ &= P(X_1|C) \cdot P(X_2|X_1C) \cdot P(X_3 \dots X_n|X_1X_2C) = \\ &= P(X_1|C) \cdot P(X_2|X_1C) \cdot P(X_3|X_1X_2C) \cdot \dots \cdot P(X_n|X_1X_2 \dots X_{n-1}C) \end{aligned}$$
- $$P(X_1X_2 \dots X_n) = P(X_1|X_2 \dots X_n) \cdot P(X_2|X_3 \dots X_n) \cdot \dots \cdot P(X_{n-1}|X_n) \cdot P(X_n)$$



verižno
pravilo

- potrebujemo veliko število pogojnih verjetnosti, katerih poznavanje je v praksi težavno
- število kombinacij pogojnih verjetnosti je glede možne vrednosti $X_1X_2 \dots X_n$ eksponentno
- praktična rešitev: **naivni Bayesov klasifikator**

Naivni Bayes v strojnem učenju

- predpostavimo, da so atributi med seboj **verjetnostno neodvisni** in poenostavimo:

$$P(X_1 X_2 \dots X_n | C) = P(X_1 | C) \cdot P(X_2 | X_1 C) \cdot \dots \cdot P(X_n | X_1 X_2 \dots X_{n-1} C)$$

$$P(X_1 X_2 \dots X_n) = P(X_1 | X_2 \dots X_n) \cdot P(X_2 | X_3 \dots X_n) \cdot \dots \cdot P(X_{n-1} | X_n) \cdot P(X_n)$$



$$P(X_1 X_2 \dots X_n | C) \approx P(X_1 | C) \cdot P(X_2 | C) \cdot \dots \cdot P(X_n | C)$$

$$P(X_1 X_2 \dots X_n) \approx P(X_1) \cdot P(X_2) \cdot \dots \cdot P(X_{n-1}) \cdot P(X_n)$$

- približki so dobri, **če so atributi med seboj dovolj neodvisni**
- velja torej:

$$P(C | X_1 X_2 \dots X_n) = \frac{P(C) \cdot P(X_1 X_2 \dots X_n | C)}{P(X_1 X_2 \dots X_n)} \approx \frac{P(C) \cdot \prod_i P(X_i | C)}{\prod_i P(X_i)}$$

konstanten člen, ki je neodvisen od ciljne spremenljivke
(če opazujemo samo relativne velikosti napovedi
različnih razredov, ga lahko izpustimo)



Naivni Bayes v strojnem učenju

- Bayesov klasifikator: primer **klasificiramo v razred, ki je najbolj verjeten**:

$$h(C_k | X_1 X_2 \dots X_n) = \operatorname{argmax}_k P(C_k) \cdot \prod_{i=1}^n P(X_i | C_k)$$



(to ni več verjetnost)

- **učenje**: ocenimo verjetnosti $P(C_k)$ in $P(X_i | C_k)$ za vse razrede C_k in vrednosti atributov X_i
- **napovedovanje**: uporabimo zgornjo enačbo za napovedovanje razreda novim primerom
- *opomba: s poenostavitvijo formule in izpustitvijo imenovalca izgubimo verjetnostno interpretacijo (verjetnosti razredov se ne seštevajo več v 1). Problem rešujemo npr. z normalizacijo rezultatov.*

Primer

- Zajeli smo podatke za 1000 sadežev, ki so lahko bodisi: *banana*, *pomaranča* ali *drugi sadež* (= vrednosti **razreda**). Za vsakega izmed sadežov smo izmerili, ali je *podolgovat*, *sladek* in *rumen* (= **atributi**). Meritve smo zapisali v tabelo:

sadež	podolgovat		sladek		rumen		skupaj
	da	ne	da	ne	da	ne	
banana	400	100	350	150	450	50	500
pomaranča	0	300	150	150	300	0	300
drugo	100	100	150	50	50	150	200
	500	500	650	350	800	200	1000

- iz tabele lahko razberemo različne verjetnosti, npr.:
 - verjetnosti razredov: $P(banana) = \frac{500}{1000} = 0,5$, $P(pomaranča) = 0,3$, $P(drugo) = 0,2$
 - pogojne verjetnosti: $P(dolg|banana) = \frac{4}{5} = 0,8$
 $P(sladek|banana) = 0,7$
 $P(rumen|banana) = 0,9$

Primer

sadež	podolgovat		sladek		rumen		skupaj
	da	ne	da	ne	da	ne	
banana	400	100	350	150	450	50	500
pomaranča	0	300	150	150	300	0	300
drugo	100	100	150	50	50	150	200
	500	500	650	350	800	200	1000

- Imamo sadež, ki ni podolgovat, ni sladek, je pa rumen. Kateri sadež je to?

$$\begin{aligned} &P(\text{banana} | \text{neP}, \text{neS}, \text{daR}) \\ &\approx P(\text{banana}) \cdot P(\text{neP} | \text{banana}) \cdot P(\text{neS} | \text{banana}) \cdot P(\text{daR} | \text{banana}) = \\ &= \frac{500}{1000} \cdot \frac{100}{500} \cdot \frac{150}{500} \cdot \frac{450}{500} = 0,5 \cdot 0,2 \cdot 0,3 \cdot 0,9 = 0,027 \end{aligned}$$

$$P(\text{pomaranča} | \text{neP}, \text{neS}, \text{daR}) \approx 0,3 \cdot 1 \cdot 0,5 \cdot 1 = 0,15$$

$$P(\text{drugo} | \text{neP}, \text{neS}, \text{daR}) \approx 0,2 \cdot 0,5 \cdot 0,25 \cdot 0,25 = 0,00625$$



ta sadež je
najverjetneje
pomaranča



Izpitna naloga

- 2. izpitni rok, 15. 2. 2018 (prilagojena naloga)

2. NALOGA (25t):


Podana je učna množica primerov, ki je prikazana v tabeli (*vreme* in *pritisk* sta atributa, *glavobol* pa je razred). Naloge:

V kateri razred bi naivni Bayesov klasifikator klasificiral učni primer z vrednostmi atributov *vreme=deževno*, *pritisk=srednji* (verjetnosti računamo z relativno frekvenco)?

vreme	pritisk	glavobol
sončno	nizek	ne
sončno	nizek	ne
sončno	srednji	da
sončno	visok	ne
sončno	nizek	ne
sončno	nizek	da
deževno	srednji	ne
deževno	srednji	da
deževno	visok	da


Pregled

- strojno učenje
 - uvod v strojno učenje
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - naključni gozdovi
 - ocenjevanje učenja
 - diskretizacija atributov, obravnava manjkajočih vrednosti
 - naivni Bayesov klasifikator
 - nomogrami
 - k najbližjih sosedov
 - lokalno utežena regresija
 - regresijska drevesa
 - linearna regresija
 - nevronske mreže
 - nenadzorovano učenje




Nomogrammi

- pristop za **vizualizacijo** naivnega Bayesovega modela
- "nomogram":
 - je *grafična upodobitev numeričnih odnosov med spremenljivkami*
 - omogoča uporabniku grafično pridobiti rezultat brez računanja
- uporaba:
 - matematika (iskanje vrednosti funkcij)
 - zdravniki v medicini (napovedovanje bolezni – npr. infarkta ali raka na podlagi vhodnih atributov)
- prikazuje:
 - pomembnost posameznih **vrednosti** vsakega atributa na ciljni razred
 - pomembnost posameznih **atributov** na ciljni razred
 - **vizualno razlago** napovedanih verjetnosti (brez kalkulatorja)



Primer - ideja



- vsaka **vrednost atributa doprinaša določeno število točk** k ciljnemu razredu
- točke vseh vrednosti atributov seštejemo v **skupno vsoto točk**, ki je povezana z verjetnostjo ciljnega razreda
- **razpon točk vsakega atributa** govori o pomembnosti atributa za napovedovanje ciljnega razreda (zgoraj urejeni od najbolj do najmanj pomembnega)

Izračun nomograma


- verjetje razreda pri naivnem Bayesu:

$$h(C|X_1X_2 \dots X_n) = P(C) \cdot \prod_{i=1}^n P(X_i|C)$$

- na zgornjem pravilu uporabimo logistično funkcijo (verjetnosti z intervala $[0,1]$ preslikamo na interval $(-\infty, \infty)$, uporabimo logaritme)

$$\text{logit } P = \log \frac{P}{1-P}$$

← logistična funkcija



- $\text{logit } h(C|X_1X_2 \dots X_n) =$
$$\log \frac{P(C) \cdot \prod_{i=1}^n P(X_i|C)}{1 - P(C) \cdot \prod_{i=1}^n P(X_i|C)} = \log \frac{P(C) \cdot \prod_{i=1}^n P(X_i|C)}{P(\bar{C}) \cdot \prod_{i=1}^n P(X_i|\bar{C})} = \log \frac{P(C)}{P(\bar{C})} + \log \frac{\prod_{i=1}^n P(X_i|C)}{\prod_{i=1}^n P(X_i|\bar{C})}$$
$$= \text{logit } P(C) + \sum_i \log \frac{P(X_i|C)}{P(X_i|\bar{C})}$$

samo ta člen je odvisen od vrednosti atributov X_i ,
to količino imenujemo razmerje verjetja
(odds ratio)

Izračun nomograma

- $\text{logit } P(C) + \sum_i \log \frac{P(X_i|C)}{P(X_i|\bar{C})} = \text{logit } P(C) + \sum_i \log OR(X_i)$
- od zgornjih členov je edino razmerje verjetja (drugi člen) **odvisno od vrednosti atributov X_i** , torej ga lahko uporabimo za "točkovanje" doprinosa atributa:

$$\text{točke}(C|X_i) = \log OR(X_i) = \log \frac{P(X_i|C)}{P(X_i|\bar{C})}$$

- **skupno število točk** za verjetnost celotnega primera (upoštevamo vse attribute):

$$\text{točke}(C|X_1X_2 \dots X_n) = \sum_i \log OR(X_i) = \sum_i \log \frac{P(X_i|C)}{P(X_i|\bar{C})}$$

- Kako izračunati **izraz znotraj logaritma $OR(X_i)$** ? Po Bayesovem pravilu (znova) velja:

$$\frac{P(X_i|C)}{P(X_i|\bar{C})} = \frac{\frac{P(C|X_i) \cdot P(X_i)}{P(C)}}{\frac{P(\bar{C}|X_i) \cdot P(X_i)}{P(\bar{C})}} = \frac{\frac{P(C|X_i)}{P(C)}}{\frac{P(\bar{C}|X_i)}{P(\bar{C})}} = \frac{\frac{P(C|X_i)}{P(\bar{C}|X_i)}}{\frac{P(C)}{P(\bar{C})}}$$

to količino imenujemo
razmerje verjetja
(odds ratio)



Primer

- učna množica titanic, 2201 učnih primerov (711 preživelih – razred YES, 1490 umrlih – razred NO)

atribut	vrednost	razred = YES	razred = NO
status	first	203	122
	second	118	167
	third	178	528
	crew	212	673
age	adult	654	1438
	child	57	52
sex	male	367	1364
	female	344	126
razred		711	1490

- Kako konstruiramo nomogram?
- Kako lahko vizualiziramo odločitev za **odraslega moškega**, ki je potoval v **drugem** razredu?


Konstrukcija nomograma

$$\text{točke}(\text{yes}|\text{status} = \text{first}) = \log \frac{\frac{P(\text{yes}|\text{first})}{P(\text{no}|\text{first})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{203}{122}}{\frac{711}{1490}} = \log \frac{1,66}{0,48} = 1,25$$

$$\text{točke}(\text{yes}|\text{status} = \text{second}) = \log \frac{\frac{P(\text{yes}|\text{second})}{P(\text{no}|\text{second})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{118}{167}}{\frac{711}{1490}} = \log \frac{0,71}{0,48} = 0,39$$


$$\text{točke}(\text{yes}|\text{status} = \text{third}) = \log \frac{\frac{P(\text{yes}|\text{third})}{P(\text{no}|\text{third})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{178}{528}}{\frac{711}{1490}} = \log \frac{0,34}{0,48} = -0,35$$

$$\text{točke}(\text{yes}|\text{status} = \text{crew}) = \log \frac{\frac{P(\text{yes}|\text{crew})}{P(\text{no}|\text{crew})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{212}{673}}{\frac{711}{1490}} = \log \frac{0,32}{0,48} = -0,42$$



Konstrukcija nomograma

- osi ostalih atributov **poravnamo glede na ničelno vrednost** prispevka atributa
- prikažemo lahko tudi **skupno skalo** za celotno napoved (vsoto točk)
- točke posameznih vrednosti atributov (log OR) lahko skaliramo v skalo točk, kjer s 100 točkami predstavimo prispevek največje vrednosti atributa



dejanske ali
normalizirane točke
atributa

skupna vsota točk

preslikava v verjetnosti

- skupne točke lahko preslikamo nazaj v verjetnosti

Neobvezna dodatna literatura: Možina, Martin, et al. "Nomograms for visualization of naive Bayesian classifier." European Conference on Principles of Data Mining and Knowledge Discovery. Springer, Berlin, Heidelberg, 2004.


Primer

- Kako lahko pojasnimo odločitev, da je **odrasli moški**, ki je potoval v **drugem** razredu, **preživel**?

$$\text{točke}(\text{yes}|\text{age} = \text{adult}) = \log \frac{\frac{P(\text{yes}|\text{adult})}{P(\text{no}|\text{adult})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{654}{711}}{\frac{1438}{1490}} = \log \frac{0,45}{0,48} = -0,05$$


$$\text{točke}(\text{yes}|\text{sex} = \text{male}) = \log \frac{\frac{P(\text{yes}|\text{male})}{P(\text{no}|\text{male})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{367}{711}}{\frac{1364}{1490}} = \log \frac{0,27}{0,48} = -0,57$$

$$\text{točke}(\text{yes}|\text{status} = \text{second}) = \log \frac{\frac{P(\text{yes}|\text{second})}{P(\text{no}|\text{second})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{118}{711}}{\frac{167}{1490}} = \log \frac{0,71}{0,48} = 0,39$$



Primer

- Kako lahko pojasnimo odločitev, da je **odrasli moški**, ki je potoval v **drugem** razredu, **preživel**?
- $točke(yes|adult, male, second) = -0,05 - 0,57 + 0,39 = -0,23$



Izpitna naloga

- 3. izpitni rok, 2. 9. 2019

3. NALOGA (10t):

Podana je učna množica podatkov o pacientih, ki so zboleli za srčno boleznijo. Ta vsebuje dva atributa:

- **družina**: če je za sorodno boleznijo zbolel tudi še kak ožji družinski član (vrednosti: da/ne)
- **spol**: spol pacienta (vrednosti: moški/ženska).

Vsak učni primer je označen z razredom **bolezen**, ki pove, ali je pacient zbolel (vrednosti: da/ne).

Povzetek števila učnih primerov s posameznimi vrednostmi atributov je podan z naslednjo tabelo:

		bolezen	
		DA	NE
družina	da	200	150
	ne	120	110
spol	moški	140	160
	ženska	180	100

b.) Nariši nomogram za verjetnostno razlago modela za klasificiranje v razred bolezen=DA. Nomogram naj prikazuje:


- skalo za prispevke atributa, ki naj prikazuje izračunano število točk (skaliranje ni potrebno),
- os za vsak atribut z jasno označenimi prispevki njegovih posameznih vrednosti.

Pri izračunu uporablja naravni logaritem.

c) Pacient s kakšnimi lastnostmi ima največjo verjetnost, da ostane zdrav (pojasni odgovor)?


Pregled

- strojno učenje
 - uvod v strojno učenje
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - naključni gozdovi
 - ocenjevanje učenja
 - diskretizacija atributov, obravnava manjkajočih vrednosti
 - naivni Bayesov klasifikator
 - nomogrami
 - k najbližjih sosedov
 - lokalno utežena regresija
 - regresijska drevesa
 - linearna regresija
 - nevronske mreže
 - nenadzorovano učenje




Metoda k najbližjih sosedov

- angl. k nearest neighbors
- lastnosti:
 - **neparametrična** metoda (ne ocenjuje parametrov izbranega modela)
 - učenje na podlagi **posameznih primerov** (angl. *instance-based learning*)
 - **leno učenje** (angl. *lazy learning*): z učenjem odlašča vse do povpraševanja o novem primeru
- ideja: ob vprašanju po vrednosti odvisne spremenljivke za novi primer:
 - poišči **k primerov**, ki so **najbližji** glede na podano **mero razdalje**
 - napovej
 - **pri klasifikaciji**: npr. večinski razred med sosedi
 - **pri regresiji**: npr. povprečno vrednost/mediano označb sosedov
- v izogib neodločenemu glasovanju za večinski razred pri klasifikaciji običajno izberemo, da je k liho število





Metoda k najbližjih sosedov

- pomembna je izbira ustreznega k :
 - premajhen k : pretirano prilagajanje
 - prevelik k : prešibko prilagajanje (pri $k = N$: napoved večinskega razreda)
 - v praksi običajno: $k = 5$




Metoda k najbližjih sosedov

- razdaljo običajno merimo z razdaljo Minkowskega: $L^p(x_i, x_j) = \left(\sum_k |x_{i,k} - x_{j,k}|^p \right)^{\frac{1}{p}}$
 - za $p = 2$ je to evklidska razdalja: $L^2(x_i, x_j) = \sqrt{\sum_k (x_{i,k} - x_{j,k})^2}$
 - za $p = 1$ je to manhattanska razdalja: $L^1(x_i, x_j) = \sum_k |x_{i,k} - x_{j,k}|$
- različni pristopi:
 - za zvezne attribute: razlika med vrednostima
 - za diskretne attribute: Hammingova razdalja (število neujemajočih diskretnih atributov pri obeh primerih)




Opombe

- vpliv intervala vrednosti na izračunano razdaljo vpliva na najdene najbližje sosede → **potrebna normalizacija**
- pri velikem številu dimenzij lahko postanejo primeri zelo oddaljeni – **prekletstvo dimenzionalnosti** (angl. *the curse of dimensionality*)
- implementacije iskanja najbližjih sosedov: $O(N)$, $O(\log N)$, $O(1)$



← pokritje 20% problemskega prostora s povečevanjem števila dimenzij



Izpitna naloga

- 2. izpitni rok, 15. 2. 2018 (prilagojena naloga)

2. NALOGA (25t):


Podana je učna množica primerov, ki je prikazana v tabeli (*vreme* in *pritisk* sta atributa, *glavobol* pa je razred). Naloge:

- c) V kateri razred bi klasifikator k-NN (pri $k=3$ in uporabi Hammingove razdalje) klasificiral učni primer z vrednostmi atributov *vreme=deževno*, *pritisk=srednji*?

vreme	pritisk	glavobol
sončno	nizek	ne
sončno	nizek	ne
sončno	srednji	da
sončno	visok	ne
sončno	nizek	ne
sončno	nizek	da
deževno	srednji	ne
deževno	srednji	da
deževno	visok	da

Pregled

- strojno učenje
 - uvod v strojno učenje
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - naključni gozdovi
 - ocenjevanje učenja
 - diskretizacija atributov, obravnava manjkajočih vrednosti
 - naivni Bayesov klasifikator
 - nomogrami
 - k najbližjih sosedov
 - lokalno utežena regresija
 - regresijska drevesa
 - linearna regresija
 - nevronske mreže
 - nenadzorovano učenje




k najbližjih sosedov za regresijo


- poišči k primerov, ki so najbližji glede na podano mero razdalje
- možnosti za izračun napovedi:
 - povprečna vrednost/mediana označb sosedov
 - utežena vsota
- **uteževanje z razdaljo** (lokalno utežena regresija)
 - $h(x_?) = \frac{\sum_{i=1}^k w_i \cdot f(x_i)}{\sum_{i=1}^k w_i}$
 - w_i je utež, ki je lahko enaka $w_i = \frac{1}{(d(x_?, x_i))^2}$
 - pri uteževanju se lahko uporablja tudi poljubna jedrna funkcija, npr. Gaussovo jedro:

$$\frac{1}{\sqrt{2\pi}} e^{-\frac{(d(x_?, x_i))^2}{2}}$$

5 nearest neighbors





100 nearest neighbors






k najbližjih sosedov za regresijo

- primer v 2 dimenzijah (atribut X in odvisna spremenljivka Y)



Pomen širine jedra za prileganje podatkom



Izpitna naloga

- 2. izpitni rok, 12. 2. 2020 (prilagojena naloga)

1. NALOGA (10t):

Učna množica vsebuje 5 učnih primerov, katerih medsebojne razdalje (izračunane z neko mero razdalje) so podane v tabeli na desni strani.


c.) Primeri 1-3 imajo vrednost odvisne spremenljivke enako 10, primera 4-5 pa vrednost odvisne spremenljivke enako 20. Kako bi naslednji napovedni modeli klasificirali primer z zaporedno številko 4 (predpostavi, da ga izločimo iz učne množice in obravnavamo kot testni ali nevideni primer):

	1	2	3	4	5
1	0	18	14	14	16
2	18	0	4	20	26
3	14	4	0	20	22
4	14	20	20	0	26
5	16	26	22	26	0

- klasifikacijski model 3-NN:
- regresijski model 3-NN:
- lokalno utežena regresija s funkcijo za uteževanje primerov $w = 1$:


Pregled

- strojno učenje
 - uvod v strojno učenje
 - učenje odločitvenih dreves
 - učenje dreves iz šumnih podatkov (rezanje dreves)
 - naključni gozdovi
 - ocenjevanje učenja
 - diskretizacija atributov, obravnava manjkajočih vrednosti
 - naivni Bayesov klasifikator
 - nomogrami
 - k najbližjih sosedov
 - lokalno utežena regresija
 - regresijska drevesa
 - linearna regresija
 - nevronske mreže
 - nenadzorovano učenje





Regresijska drevesa

- **zvezna ciljna spremenljivka** – regresijski problem
- regresijska drevesa so podobna odločitvenim drevesom, le za regresijske probleme
- sistemi: CART (Breiman et al. 1984), RETIS (Karalič 1992), M5 (Quinlan 1993), WEKA (Witten and Frank, 2000)
- listi v regresijskem drevesu predstavljajo bodisi:
 - **povprečno vrednost** označb ("razreda") primerov v listu
 - **preprost napovedni model** (npr. linearna regresija) za nove primere



Regresijska drevesa




Gradnja regresijskih dreves

- drugačna mera za merjenje nedoločenosti/nečistoče: srednja kvadratna napaka v vozlišču v :

$$MSE(v) = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

- cilj: minimiziramo rezidualno nedoločenost po delitvi primerov glede na vrednosti atributa A
- pričakovana rezidualna nečistost


$$I_{res}(A) = p_{left} \cdot I_{left} + p_{right} \cdot I_{right}$$



Primer

- napovedovanje števila točk pri igri

spol	konzola	točke
M	T	1
M	T	3
M	F	5
F	T	4
F	T	9
F	F	3




$$I_{res}(A) = p_{left} \cdot I_{left} + p_{right} \cdot I_{right}$$

$$MSE(v) = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

$$I_{res}(spol) = \frac{3}{6} \left[\frac{(1-3)^2 + (3-3)^2 + (5-3)^2}{3} \right] + \frac{3}{6} \left[\frac{(4-5,33)^2 + (9-5,33)^2 + (3-5,33)^2}{3} \right] = 4,77$$

$$I_{res}(konzola) = \frac{4}{6} \left[\frac{(1-4,25)^2 + (3-4,25)^2 + (4-4,25)^2 + (9-4,25)^2}{4} \right] + \frac{2}{6} \left[\frac{(5-4)^2 + (3-4)^2}{2} \right] = 6,125$$





Regresija...